PROPOSAL PENELITIAN

JUDUL PENELITIAN	Prediksi Customer Churn pada Layanan Telekomunikasi Menggunakan CatBoost dengan Interpretasi SHAP untuk Mendukung Strategi Retensi Pelanggan
Nama	Reno Naufal Maulidyan
NPM	23081010026
Program Studi	Informatika

BAB I: PENDAHULUAN

1.1 Latar Belakang

Di industri telekomunikasi yang sangat kompetitif, menjaga keberlangsungan pelanggan (*customer retention*) merupakan aspek krusial bagi stabilitas pendapatan perusahaan. Biaya akuisisi pelanggan baru secara umum jauh lebih tinggi dibandingkan biaya untuk mempertahankan pelanggan yang sudah ada. Fenomena berpindahnya atau berhentinya pelanggan dari penggunaan layanan (*customer churn*) dapat mengakibatkan kerugian finansial yang signifikan jika tidak dideteksi dan ditangani secara dini.
Pada dataset publik IBM Telco Customer Churn, tingkat *churn* tercatat mencapai 26,5% (1.869 dari total 7.043 pelanggan). Tingginya proporsi ini mengindikasikan perlunya sistem peringatan dini (*early warning system*) berbasis *machine learning* untuk mengidentifikasi pelanggan yang berpotensi melakukan *churn*. Namun, dalam praktik bisnis *Customer Relationship Management* (CRM), sekadar memprediksi atau mendeteksi risiko *churn* secara tepat tidaklah cukup jika tidak dibarengi dengan pemahaman mendalam mengenai faktor pemicunya serta arahan tindakan penanganan yang presisi.

1.2 Rumusan Masalah

1. Bagaimana kinerja *CatBoost Classifier* dalam memprediksi *customer churn* pada layanan telekomunikasi berdasarkan metrik *Recall*, *F1-score*, dan *ROC-AUC*?
2. Faktor apa saja yang berkontribusi terhadap prediksi *churn* berdasarkan interpretasi SHAP (global dan lokal), dan bagaimana faktor tersebut dipetakan secara eksplisit menjadi rekomendasi tindakan retensi?

1.3 Batasan Masalah

1. Dataset yang digunakan adalah dataset publik IBM Telco Customer Churn dari repository Kaggle (7.043 baris data dan 21 atribut).
2. Algoritma pembelajaran mesin yang dievaluasi berfokus pada CatBoost Classifier.

3. Penanganan *class imbalance* difokuskan pada optimasi teknik *class weight* bawaan pada data riil tanpa pembuatan data sintetis (SMOTE).
4. Interpretasi model dibatasi pada metode SHAP tingkat global (*Summary Beeswarm Plot*) dan tingkat lokal (*Waterfall Plot*).
5. Luaran tindakan retensi merupakan usulan panduan operasional berbasis analisis data (bukan hasil uji eksperimen lapangan langsung).

1.4 Tujuan Penelitian

1. Menganalisis dan mengukur kinerja *CatBoost Classifier* dalam memprediksi *customer churn* berbasis metrik *Recall*, *F1-score*, dan *ROC-AUC*.
2. Menganalisis faktor pemicu *churn* menggunakan SHAP global dan lokal, serta memetakkannya secara eksplisit menjadi tabel rekomendasi tindakan retensi pelanggan yang konkret dan dapat ditindaklanjuti.

1.5 Manfaat Penelitian

- Manfaat Akademis: Memberikan kontribusi literatur dalam penerapan *Explainable AI* (XAI) pada kasus klasifikasi biner, khususnya dalam menjembatani keluaran numerik SHAP menjadi pemetaan keputusan bisnis yang terstruktur.
- Manfaat Praktis: Menjadi acuan bagi tim operasional/pemasaran industri telekomunikasi dalam merancang strategi retensi pelanggan yang presisi berdasarkan faktor dominan pemicu *churn*.

BAB II: TINJAUAN PUSTAKA DAN KERANGKA PEMIKIRAN

2.1 Landasan Teori

1. *Customer Churn*: Kondisi ketika pelanggan memutuskan untuk berhenti menggunakan layanan suatu perusahaan. Dalam skala bisnis, prediksi *churn* bertujuan untuk mengidentifikasi pelanggan berisiko tinggi sebelum mereka benar-benar keluar.
2. *CatBoost Classifier*: Algoritma *gradient boosting* pada *decision trees* yang dioptimalkan untuk menangani variabel kategorikal secara *native* menggunakan teknik *Ordered Target Statistics*, sehingga mengurangi ketergantungan pada *one-hot encoding* serta meminimalkan risiko *overfitting*.
3. *Class Imbalance & Class Weight*: Kondisi di mana proporsi kelas target tidak seimbang (26,5% *churn* vs 73,5% *non-churn*). Teknik *class weight* memberikan bobot penalti lebih besar pada kesalahan klasifikasi kelas minoritas (*churn*) selama proses *loss function*.
4. *SHAP (SHapley Additive exPlanations)*: Metode berbasis teori permainan (*game theory*) yang menghitung kontribusi marjinal (*Shapley value*) dari setiap fitur prediktor terhadap luaran prediksi model.

2.2 Research Gap (Kesenjangan Penelitian) dan Tinjauan Pustaka

Penelitian terdahulu mengenai prediksi *churn* dan interpretasi model memiliki beberapa keterbatasan utama:

No	Peneliti & Tahun	Judul Penelitian	Hasil Utama	Research Gap / Keterbatasan
1	Azzahra & Agastya (2026)	Prediksi Churn Pelanggan Telekomunikasi...	RF terbaik (ROC-AUC 0.833, F1 0.611) dengan SMOTE.	Tidak melaporkan tuning & CV; SHAP sebatas bar plot tanpa memperlihatkan arah pengaruh.
2	Ali dkk. (2026)	Data-Driven Telecom Marketing Optimization...	CatBoost mencapai ROC-AUC 0.840 dan F1 0.636.	SHAP hanya bar plot rata-rata; strategi disusun per segmen risiko umum, bukan diturunkan dari SHAP.
3	Damuri dkk. (2026)	Prediksi Customer Churn Berbasis Nilai Pelanggan...	XGBoost terbaik (ROC-AUC 0.991) pada Iranian Churn.	Dataset berbasis pola penggunaan; belum ada pemetaan eksplisit faktor SHAP ke aksi retensi operasional.
4	Wang & Zhang (2024)	Research on telecom industry customer churn...	CatBoost terbaik (Akurasi 0.852, ROC-AUC 0.926).	Menggunakan data operasional privat (tidak reproducible); SHAP sebatas tafsir naratif.
5	Nur dkk. (2025)	Improving Customer Churn Prediction Using...	CatBoost + Optuna mencapai ROC-AUC 0.937.	Validitas counterfactual sangat rendah (0.200); belum ada pemetaan eksplisit ke tindakan bisnis.

Sintesis Research Gap:

Sebagian besar studi terdahulu hanya berhenti pada tahap menampilkan grafik peringkat faktor SHAP, segmentasi kelompok umum, atau simulasi angka tanpa memberikan panduan eksekusi retensi yang spesifik. Research gap yang diselesaikan oleh penelitian ini adalah menghubungkan secara langsung nilai kontribusi SHAP global dan lokal beserta arah pengaruhnya (+/-) menjadi Tabel Pemetaan Eksplisit Aksi Retensi Pelanggan pada dataset publik IBM Telco yang teruji dan dapat direproduksi (reproducible).

2.3 Research Mind Map (Kerangka Pemikiran Penelitian)

Kerangka pemikiran dan alur logika penelitian ini dirancang secara terstruktur melalui peta konsep berikut:

Tahap Kerangka	Komponen dan Alur Logika Penelitian
1. Permasalahan Bisnis & Data	Tingginya tingkat customer churn di industri telekomunikasi (26,5% pada IBM Telco) dan tingginya biaya akuisisi pelanggan baru. Sekadar mendeteksi churn tidak cukup tanpa mengetahui tindakan retensi yang presisi.
2. Pendekatan Pemodelan	Penerapan CatBoost Classifier dengan optimasi class weight pada data riil, tervalidasi secara objektif melalui Stratified 5-Fold Cross-Validation untuk mengukur kestabilan model.
3. Explainable AI (XAI)	Penerapan SHAP dua tingkat: Global (Summary Beeswarm Plot) untuk melihat hierarki & arah pengaruh fitur, serta Lokal (Waterfall Plot) untuk sampel individu berisiko tinggi.
4. Kebaharuan (Novelty)	Jembatan eksplisit dari interpretasi numerik SHAP dan arah pengaruhnya (+/-) menuju tindakan operasional retensi pelanggan yang terstruktur.
5. Luaran Akhir (Output)	Tabel Pemetaan Rekomendasi Retensi Operasional yang siap ditindaklanjuti oleh tim operasional/pemasaran CRM.

BAB III: METODOLOGI PENELITIAN

3.1 Dataset Rencana Riset

Rencana riset ini menggunakan dataset publik IBM Telco Customer Churn dari repository Kaggle.

Karakteristik dataset dirinci sebagai berikut:

- Ukuran Data: 7.043 baris data pelanggan dengan 21 atribut.
- Variabel Terikat (Target): Churn (Status berhenti/tetap berlangganan, terdiri dari 1.869 data Churn / 26,5% dan 5.174 data Non-Churn / 73,5%).
- Variabel Bebas (Features): 19 atribut prediktor yang dikelompokkan dalam 3 kategori utama:
    - Demografi: gender, SeniorCitizen, Partner, Dependents.
    - Layanan Telekomunikasi: tenure, PhoneService, MultipleLines, InternetService, OnlineSecurity, OnlineBackup, DeviceProtection, TechSupport, StreamingTV, StreamingMovies.
    - Kontrak & Finansial: Contract, PaperlessBilling, PaymentMethod, MonthlyCharges, TotalCharges.
- Variabel Identifikator: customerID (dihapus saat pra-pemrosesan data karena tidak memiliki nilai prediktif).

3.2 Tahapan dan Alur Penelitian

Pelaksanaan penelitian mengikuti alur langkah terstruktur:

1. Pengumpulan Data: Memuat dataset resmi IBM Telco Customer Churn.
2. Pra-pemrosesan Data: Pembersihan data, eliminasi customerID, penanganan tipe data TotalCharges, dan penanganan variabel kategorikal.
3. Pembagian Data & Pemodelan: Penerapan Stratified Split serta penanganan class imbalance menggunakan teknik class weight pada CatBoost Classifier.
4. Validasi Pemodelan: Evaluasi menggunakan Stratified 5-Fold Cross-Validation untuk memastikan konsistensi performa di setiap lipatan data.
5. Analisis SHAP Global & Lokal: Ekstraksi nilai SHAP beeswarm plot untuk melihat pola umum dan waterfall plot untuk kasus pelanggan individu.
6. Penyusunan Tabel Retensi: Memetakan hasil SHAP secara terstruktur menjadi panduan aksi bisnis.

3.3 Rencana Evaluation Metric

Untuk mengukur keberhasilan dan performa model klasifikasi CatBoost secara objektif, penelitian ini menggunakan rencana metrik evaluasi berikut:

- Recall (Sensitivity): Mengukur sejauh mana model mampu mengidentifikasi seluruh pelanggan yang sebenarnya melakukan churn. Metrik ini diprioritaskan utama untuk meminimalkan True Negative / pelanggan churn yang luput dari deteksi. Formula: Recall = TP / (TP + FN).
- F1-Score: Mengukur keseimbangan antara Precision dan Recall. Metrik ini penting karena proporsi kelas target tidak seimbang (imbalanced data). Formula: F1 = 2 * (Precision * Recall) / (Precision + Recall).
- ROC-AUC (Area Under the Receiver Operating Characteristic Curve): Mengukur kemampuan diskriminasi model dalam membedakan kelas Churn dan Non-Churn pada berbagai tingkatan threshold.
- Confusion Matrix: Matriks acuan untuk menghitung jumlah True Positive (TP), False Positive

(FP), True Negative (TN), dan False Negative (FN).

3.4 Interpretasi SHAP dan Pemetaan Retensi

Hasil interpretasi model SHAP (tingkat global dan lokal) beserta arah pengaruhnya (+/-) dipetakan secara eksplisit ke dalam Tabel Rekomendasi Retensi Operasional. Setiap fitur dominan dihubungkan dengan kondisi spesifik pelanggan serta usulan tindakan pencegahan yang konkret bagi tim pemasaran dan layanan pelanggan.